PRÉ-LEITURA · SESSÃO 1 · ÊNFASE EM IA · COPPEAD/UFRJ

Antes de comprar: desenhar a solução de IA e escrever as premissas

Seminário “IA aplicada a Operações, Processos e Supply Chain” — leitura de preparação para o exercício do Canvas, blocos A a C.

Prof. Dr. Thiago Lima

Leitura ≈ 25 min

Leve para a aula: um problema real da sua área

Esta leitura não ensina a programar nada. Ela ensina a fazer as perguntas certas **antes** de assinar um contrato de IA. Na Sessão 1, seu grupo vai desenhar uma solução de IA para um problema de operação, com apoio de um assistente (o “coach”). O resultado será um Canvas com três blocos: problema e decisão, solução, e premissas. O texto abaixo segue essa mesma ordem.

1 Uma cena conhecida

VINHETA · DISTRIBUIDORA ATLÂNTICA CASO FICTÍCIO

A Distribuidora Atlântica entrega medicamentos e materiais a 180 hospitais e clínicas do estado do Rio. O indicador que tira o sono da diretoria é a **ruptura**: em 9% dos pedidos falta pelo menos um item. Os compradores trabalham com planilhas e com a memória de quem está há vinte anos na casa.

Um fornecedor apresenta um módulo de previsão de demanda “com inteligência artificial”. A demonstração é bonita. O erro de previsão cai pela metade nos dados de teste. O contrato é assinado em março.

Seis meses depois, o erro médio de previsão de fato caiu. A ruptura, não. Ao investigar, a equipe descobre três coisas. Primeiro, os compradores continuam ajustando a previsão “por segurança”, quase sempre para cima — e o estoque sobe sem que a falta diminua. Segundo, o modelo foi ajustado para acertar a média de todos os itens; acerta muito bem a soro fisiológico e erra justamente os itens de UTI, que vendem pouco e não podem faltar. Terceiro, o sistema aprende com as **vendas** registradas. Quando o item falta, a venda não acontece — e o modelo conclui que a demanda caiu.

Ninguém mentiu. O software funciona. O que faltou foi responder, por escrito, a perguntas que não são técnicas: *que decisão isso vai apoiar? Que número deve perseguir? O que ele enxerga no lugar da demanda real?*

Guarde esta cena. Cada seção a seguir volta a ela.

2 O que a IA faz, de fato, numa operação

Uma forma útil de pensar a IA vem de três economistas, Agrawal, Gans e Goldfarb (2018). A ideia central é simples: **a IA torna a predição barata**. Predição, aqui, é usar dados que você tem para estimar algo que você não tem. Quanto vamos vender na semana que vem. Qual máquina deve quebrar primeiro. Qual nota fiscal parece errada.

Toda decisão tem dois ingredientes: predição e julgamento. Julgamento é saber o que importa e quanto custa errar para cada lado. A IA leva a predição para a máquina, mas o julgamento continua com a organização. Nas palavras de Gans, a predição é "transferida para a máquina e separada do julgamento" (tradução livre).

> Predição mais barata só gera benefício quando outras atividades também mudam.
>
> Gans, entrevista ao IESE Insight, sobre Agrawal, Gans & Goldfarb (paráfrase)

É aqui que muitos projetos travam. Comprar uma previsão melhor é fácil. Mudar quem decide, com que regra e em que momento do processo é difícil. Os autores observam que soluções isoladas, como uma previsão de demanda, já funcionam. As mudanças que exigem redesenhar várias atividades ligadas — reposição automática, novo rito de planejamento — ainda são raras.

Thomas Davenport já dizia algo parecido em 2006, antes da onda atual. No artigo "Competing on Analytics", ele descreve empresas que fizeram da análise de dados uma forma de competir. O ponto que nos interessa: nessas empresas, usar dados para decidir foi uma **decisão da organização**, sustentada pela liderança — não a compra de uma ferramenta por um departamento.

Os números recentes mostram a distância entre usar e ganhar. Na pesquisa global da McKinsey de 2025, **88%** dos respondentes dizem que suas organizações usam IA com regularidade em pelo menos uma função. Só cerca de **6%** se enquadram como "alto desempenho": impacto relevante no resultado operacional. Esses poucos têm quase três vezes mais chance de ter redesenhado seus fluxos de trabalho. Atenção: são respostas dos próprios executivos, não resultados auditados. Mesmo assim, a mensagem é clara. Usar IA virou comum. Transformar IA em resultado, não.

3 Anatomia de uma solução: decisão primeiro, modelo depois

A pergunta errada é "que IA podemos usar?". A pergunta certa começa pelo número de gestão que está ruim e pela decisão que mexe nesse número. Só depois vem o modelo. O Canvas da Sessão 1 segue essa ordem.

1 · Número ruim	2 · Decisão	3 · Quem e quando	4 · Entrega da IA	5 · Ação
Ruptura de 9%	Quanto comprar de cada item	Comprador, toda segunda	Previsão + alerta de risco	Pedido ajustado ao fornecedor

Bloco A — Problema e decisão

Comece pelo indicador. Seja específico: "ruptura de 9% dos pedidos", não "melhorar o estoque". Depois, nomeie a **decisão** que a IA vai apoiar. Uma decisão tem dono e frequência. Quem decide? Com que frequência? Em que etapa do processo? "O comprador, toda segunda-feira, ao montar o pedido semanal" é uma resposta útil. "A área de suprimentos" não é.

Bloco B — A solução

Uma solução de IA entrega uma coisa concreta. Em operações, quase sempre é uma destas cinco:

ENTREGA	EXEMPLO EM OPERAÇÕES	QUEM RECEBE E O QUE FAZ
Previsão	Demanda de cada item para as próximas 4 semanas	Comprador define a quantidade do pedido
Alerta	“Esta bomba de infusão tem sinal de falha próxima”	Engenharia clínica agenda a manutenção
Lista priorizada	Notas fiscais ordenadas por risco de erro	Analista fiscal confere as 50 primeiras
Sugestão	Rota de entrega proposta para o dia	Despachante aceita, altera ou recusa
Texto	Resumo de reclamações de clientes da semana	Gerente de qualidade decide o que investigar

Para cada entrega, responda três coisas. **De que histórico ela aprende?** (vendas, ordens de serviço, notas, chamados). **Quem recebe?** (uma pessoa com nome de cargo). **O que essa pessoa faz** de diferente quando recebe? Se ninguém faz nada diferente, não há solução — há um relatório a mais.

CASO REAL · ZILLOW OFFERS, 2021

A Zillow, portal imobiliário americano, comprava casas para revender. O preço de compra era apoiado por modelos próprios de precificação. Em novembro de 2021, a empresa encerrou o negócio. Registrou baixa de estoque de cerca de **US$ 304 milhões** no trimestre, por ter comprado imóveis “a preços acima das estimativas atuais de preço futuro de venda”, e anunciou corte de cerca de 25% do quadro. O CEO resumiu: a imprevisibilidade na previsão de preços “excedeu em muito o que antecipamos” (tradução livre).

Leitura para o Canvas (nossa, não da empresa): o problema não foi só a qualidade da previsão do modelo de precificação do Zillow Offers. Foi a **decisão** acoplada a ela — comprar em grande escala — sem uma regra escrita sobre quanta incerteza o balanço aguentava. Decisão primeiro, modelo depois.

Fonte: Zillow Group, 8-K e Ex. 99.1, 02/11/2021 (SEC).

4 VCAP: o que você está comprando, afinal?

Ainda no Bloco B, o Canvas pede uma classificação. A solução que vocês desenharam é um **ativo**, uma **mudança de processo** ou uma **capacidade** que fica na empresa? A lente vem do capítulo 1 de *Excelência Operacional* (Lima, 2026):

$$V = C \times (A + P)$$

Valor = Capacidade × (Ativos + Processos)

LETRA	O QUE É	NA DISTRIBUIDORA ATLÂNTICA
A	**Ativo.** Algo que se compra e se instala: software, licença, modelo pronto, equipamento.	O módulo de previsão de demanda
P	**Processo.** Uma mudança na forma de trabalhar: nova regra, novo rito, novo fluxo.	Reunião semanal em que o comprador só altera a previsão com justificativa registrada
C	**Capacidade.** O que a empresa sabe fazer e que fica nela quando o fornecedor sai: gente que entende e questiona o modelo, dados bem cuidados, regras de decisão escritas.	Equipe que sabe ler o erro por família de itens, corrigir o histórico de vendas perdidas e decidir quando não confiar na previsão

A fórmula diz duas coisas. Ativos e processos **se somam** — e ambos podem ser comprados ou copiados. A capacidade **multiplica**. Se a capacidade é perto de zero, o valor também é, por mais caro que seja o ativo.

Agora o ponto prático. A IA que se compra é quase sempre **A**. Às vezes vem com um pouco de **P** (o fornecedor ajuda a redesenhar o fluxo). Raramente é **C**. A pesquisa econômica aponta na mesma direção: o retorno de tecnologias de uso geral depende de investimentos complementares, muitas vezes invisíveis no balanço, que cada empresa precisa construir (Tambe et al., 2020).

Erro clássico: pagar por A e contabilizar como C. A diretoria acredita que "agora a empresa tem IA". Na verdade, tem uma licença. Quando o mundo muda, ninguém de dentro sabe ajustar.

5 Os três pilares: as premissas que ninguém escreve

Michael Schrage e David Kiron publicaram em 2025 um ensaio na *MIT Sloan Management Review* com um título provocador: "Philosophy Eats AI" — a filosofia come a IA. A tese: o valor de um sistema de IA depende de escolhas que parecem abstratas, mas são muito concretas. Para que o sistema serve. O que ele considera conhecimento. Como ele representa a realidade. Essas escolhas existem em todo sistema. Se a empresa não as faz, elas vêm prontas do fornecedor — ou do acaso.

Os autores usam três palavras da filosofia. Não se assuste com elas. Cada uma vira uma pergunta simples de gestão. É um ensaio de praticantes, não um estudo com dados — use-o como lente, não como prova.

Teleologia

PARA QUÊ?

O que é: o objetivo que o sistema persegue. Todo modelo é ajustado para melhorar algum número. A questão é se esse número é o que a organização quer.

Exemplo: na Distribuidora Atlântica, o modelo foi ajustado para reduzir o erro médio de todos os itens. A diretoria queria zero falta nos itens de UTI. Os dois objetivos brigam: o modelo acerta muito o item que vende muito e pouco o item raro e crítico.

Pergunte: que número o sistema persegue? Quando dois objetivos entram em conflito — custo × nível de serviço, velocidade × segurança — qual ganha, e quem decidiu isso?

Epistemologia

O QUE CONTA COMO SABER?

O que é: o que o sistema trata como conhecimento. Um modelo aprendido de dados "sabe" o que o passado mostrou. Ele não sabe, sozinho, quando o passado deixou de valer.

Exemplo real: a Instacart, de entregas de supermercado nos EUA, tinha um modelo que estimava se um produto estaria na gôndola. Em março de 2020, com a pandemia, a acurácia medida caiu de **93% para 61%**. Os dados de treino não refletiam a nova realidade de estoques esvaziados. A correção foi de processo: treinar com dados de até dez dias, em vez de semanas, e recalcular a cada hora (Fortune, 2020).

Pergunte: o que conta como "saber" para este sistema? Ele avisa quando não sabe? Que evento invalida os dados dele — uma pandemia, uma greve, um novo concorrente, uma mudança de tabela?

Ontologia

O QUE ELE ENXERGA?

O que é: como o sistema representa a realidade. Nenhum sistema vê a coisa que importa. Ele vê um **substituto** registrado em algum banco de dados.

Exemplo: na Distribuidora Atlântica, o modelo recebe "vendas" no lugar de "demanda". Quando falta o item, a venda some e a demanda parece cair. Outro caso comum `ILUSTRATIVO`: um sistema que prioriza manutenção a partir de ordens de serviço abertas. Ele não vê os defeitos que o operador resolve no improviso e nunca registra.

Pergunte: o que o sistema recebe no lugar do que realmente importa? O que ele não consegue ver? Quem revisa essa representação, e com que frequência?

6 Dívida filosófica

Todo gestor conhece a dívida técnica: atalhos de hoje que viram custo amanhã. Engenheiros do Google mostraram que, em sistemas de aprendizado de máquina, essa dívida "se acumula silenciosamente" (Sculley et al., 2015). O sistema parece funcionar enquanto os problemas crescem por baixo.

A **dívida filosófica** é a versão gerencial desse fenômeno. O termo é do capítulo 5 de *Excelência Operacional* (Lima, 2026), inspirado em Schrage & Kiron — não é expressão desses autores. Ela é o que se acumula quando as premissas dos três pilares não são escritas.

> Premissa não escrita é premissa que ninguém audita.

Na Distribuidora Atlântica, ninguém escreveu que o objetivo era o erro médio (teleologia), que o histórico de vendas não registra a falta (ontologia), nem que um surto de dengue mudaria o padrão de consumo (epistemologia). Cada omissão parecia pequena. Juntas, explicam por que a ruptura não caiu. E, como nada estava escrito, ninguém tinha como cobrar, revisar ou corrigir.

Sinais de que uma solução já carrega dívida filosófica:

- Ninguém sabe dizer, em uma frase, que número o sistema otimiza.
- O indicador do modelo melhora e o indicador do negócio não.
- Os usuários "corrigem" a saída por conta própria, sem registro.
- Não existe uma lista de eventos que obrigam a revisar o modelo.
- A única pessoa que entende as premissas é o consultor do fornecedor.

O Bloco C do Canvas existe para pagar essa dívida antes de ela começar: escrever as premissas enquanto ainda é barato.

7 Para levar à Sessão 1

Antes da aula, pense em **um problema real** da sua área — finanças, pessoas, saúde, engenharia, setor público. Não precisa ter dados nem conhecer tecnologia. Se faltar informação, o coach vai sugerir dados hipotéticos, sempre sinalizados como didáticos. Use a lista abaixo como roteiro.

CANVAS · BLOCOS A–C · CHECKLIST DE PREPARAÇÃO

A · PROBLEMA E DECISÃO

- [ ] Qual número de gestão está ruim? (com valor atual, se souber)
- [ ] Que decisão a IA vai apoiar? Quem decide e com que frequência?
- [ ] Em que etapa do processo essa decisão acontece?

B · SOLUÇÃO

- [ ] O que ela entrega: previsão, alerta, lista priorizada, sugestão ou texto?
- [ ] De que histórico ela aprende?
- [ ] Quem recebe a entrega e o que passa a fazer de diferente?
- [ ] VCAP: é ativo (A), mudança de processo (P) ou capacidade que fica na empresa (C)? O que precisaria existir para virar C?

C · PILARES FILOSÓFICOS

- [ ] **Teleologia:** que número o sistema persegue? Em conflito, qual objetivo ganha?
- [ ] **Epistemologia:** o que conta como saber? Ele sabe quando não sabe? Que evento invalida os dados?
- [ ] **Ontologia:** o que ele recebe no lugar do que importa? O que não vê? Quem revisa?
- [ ] Qual destas premissas, se ficar sem escrever, vira a maior dívida filosófica?

REF. Referências

Agrawal, A., Gans, J., & Goldfarb, A. (2018). *Prediction Machines: The Simple Economics of Artificial Intelligence*. Harvard Business Review Press. Ideias citadas via entrevista de J. Gans ao IESE Insight: iese.edu/insight/articles/artificial-intelligence-between-promise-and-adoption-joshua-gans

Davenport, T. H. (2006). Competing on analytics. *Harvard Business Review*, 84(1), 98–107. hbr.org/2006/01/competing-on-analytics

Fortune. (2020, 9 de junho). Reportagem sobre a queda de acurácia dos modelos da Instacart na pandemia. fortune.com/2020/06/09/instacart-coronavirus-artificial-intelligence

Lima, T. F. (2026). *Excelência Operacional*. Cap. 1 (VCAP: V = C × (A + P)) e cap. 5 (dívida filosófica).

McKinsey & Company. (2025). *The state of AI in 2025*. Pesquisa global, dados auto-relatados. mckinsey.com/capabilities/quantumblack/our-insights/the-state-of-ai-2025

Schrage, M., & Kiron, D. (2025). Philosophy eats AI. *MIT Sloan Management Review*. sloanreview.mit.edu/article/philosophy-eats-ai

Sculley, D., et al. (2015). Hidden technical debt in machine learning systems. *Advances in Neural Information Processing Systems 28* (NeurIPS). proceedings.neurips.cc/paper/2015/file/86df7dcfd896fcaf2674f757a2463eba-Paper.pdf

Tambe, P., Hitt, L., Rock, D., & Brynjolfsson, E. (2020). *Digital capital and superstar firms* (NBER Working Paper 28285). nber.org/papers/w28285

Zillow Group. (2021, 2 de novembro). Form 8-K, Exhibit 99.1 — resultados do 3° trimestre de 2021. SEC. sec.gov/Archives/edgar/data/1617640/000161764021000085/q32021991.htm