LEITURA PRÉVIA · SESSÃO 2 DE 3 · IA APLICADA A OPERAÇÕES, PROCESSOS E SUPPLY CHAIN

Como saber se vai funcionar

Evidência, implantação e comparação: o que perguntar antes de adotar uma solução de IA em operações.

COPPEAD/UFRJ · Ênfase em IA | Prof. Dr. Thiago Lima | Leitura: ~30 min

Prepara o Canvas · blocos D–G

Para que serve esta leitura. Na Sessão 1, seu grupo desenhou uma solução de IA para um problema de operações. Na Sessão 2, com o apoio de um coach de IA, o grupo vai completar os blocos D a G do Canvas. Esses blocos fazem uma só pergunta, de quatro jeitos: *como vamos saber se isso funciona de verdade?* Esta leitura dá o vocabulário e os números para responder sem cair nas armadilhas mais comuns. Todos os dados citados vêm de fontes verificadas, listadas no fim.

1 O número do fornecedor e a pergunta do gestor

VINHETA FICTÍCIA · CRIADA PARA FINS DIDÁTICOS

Uma rede de supermercados recebe a proposta de um fornecedor de previsão de demanda. O slide principal diz: **"acurácia de 95%"**. A diretora de operações pergunta: "Quantas rupturas a menos eu vou ter na loja de Madureira, no corredor de laticínios, numa terça-feira?"

O fornecedor responde que os 95% são "a média da rede, por mês". Ninguém sabe dizer quanto disso chega à prateleira. Nem quem vai olhar a previsão antes de fazer o pedido. Nem o que acontece quando o comprador discorda.

As duas pessoas falam de coisas diferentes. O fornecedor fala do **modelo**: quanto a previsão se aproxima da venda real. A diretora fala do **resultado**: menos prateleira vazia, menos estoque parado, menos dinheiro perdido. Entre um e outro há uma corrente de elos. A previsão precisa ser boa no nível em que a decisão é tomada. Precisa chegar a tempo. Alguém precisa usá-la. A ação precisa acontecer. E o ganho precisa ser medido contra uma comparação justa.

Esta leitura percorre essa corrente na ordem dos blocos do Canvas: **D** (evidência), **E** (implantação), **F** (resultado e valor) e **G** (o ELO antes da adoção).

2 · BLOCO D A escada de evidência

Nem toda prova vale o mesmo. Quando alguém diz que "IA funciona", a primeira pergunta é: **que tipo de prova é essa?** Use a escada abaixo. Quanto mais alto o degrau, mais perto do resultado que a diretora quer ver.

ESCADA DE EVIDÊNCIA · DO MAIS FRACO AO MAIS FORTE

DEGRAU	O QUE MEDE	EXEMPLO EM OPERAÇÕES	O QUE NÃO PROVA
1	**Métrica do modelo**: erro da previsão, acerto da classificação	"Erro médio de 8% na previsão"; "acerta 94% das categorias de compra"	Que alguém usou a previsão, ou que o estoque caiu
2	**Benefício esperado**: simulação, business case, proposta do fornecedor	"Com essa acurácia, o estoque *pode* cair 20%"	Que a simulação vale para a sua operação real
3	**Percepção do usuário**: pesquisa, entrevista, depoimento	"80% dos planejadores acham que melhorou"	Que melhorou. Percepção e medição podem divergir muito (seção 6)
4	**Resultado transacional com comparação**: dados reais do sistema, contra um grupo que não usou a solução	Lojas com o sistema vs. lojas sem o sistema, no mesmo período, medindo vendas ou rupturas	Ainda precisa checar se o ganho compensa o custo (seção 7)

Junto com o degrau, faça mais duas perguntas: **quem mediu?** e **quem mediu vende a solução?** Um número do próprio fornecedor, ou da empresa que quer mostrar inovação, é `auto-reportado`. Um número de pesquisadores independentes, de um júri ou de um regulador é `independente`. Os dois podem ser verdadeiros. Mas valem pesos diferentes.

O que diz a melhor revisão disponível

Culot, Podrecca e Nassimbeni (2024) fizeram uma revisão sistemática da literatura sobre IA em supply chain. Partiram de 3.173 artigos e ficaram com **123 estudos empíricos que usaram dados reais** de empresas. Simulações e dados inventados foram excluídos de propósito. Ou seja: é o "melhor da turma".

Mesmo assim, ao tratar de desempenho, os autores concluem que os benefícios relatados

> "são frequentemente expectativas ou resultados percebidos." `Culot et al., 2024 (tradução livre)`

Em linguagem de escada: a maior parte da literatura está nos degraus 1, 2 e 3. Os autores também notam que as decisões de custo-benefício costumam ser "de percepção": poucas empresas montam um business case estruturado. E um dos estudos revisados relata que **50% a 80% do tempo de projeto vai para coletar e limpar dados**. Antes de qualquer ganho, há muito trabalho de base.

3 · BLOCO D2 O total e o detalhe

A melhor evidência independente sobre previsão de demanda vem de uma competição internacional, a **M5** (Makridakis, Spiliotis & Assimakopoulos, 2022). Mais de 5.500 equipes tentaram prever as vendas de produtos do Walmart, em 42.840 séries de dados. A organização era independente `independente`. Os resultados mostram algo que todo gestor deveria saber:

~22%	~3%	7,5%
melhor que o método estatístico de referência, no total agregado	melhor no nível *produto em cada loja*, onde o pedido é feito	das equipes bateram a referência com a versão que escolheram enviar

Leia os três números juntos. A IA (aqui, aprendizado de máquina: programas que aprendem padrões a partir de dados históricos) ganhou com folga no **total**. Mas, no nível em que se decide quanto repor de cada produto em cada loja, o

ganho caiu para cerca de 3%. E só 7,5% das equipes bateram um método estatístico simples com a versão que escolheram enviar. Muitas escolheram mal, porque testaram numa janela de dados que as enganou. Os próprios autores registram que a acurácia **não foi ligada aos custos operacionais** do Walmart. Ou seja: mesmo aqui, estamos no degrau 1.

> LIÇÃO PARA O BLOCO D2 · UMA DECISÃO, NÃO UM DADO
> Pergunte "quão boa a solução precisa ser?" no nível de detalhe **da decisão**, não do relatório. Se a decisão é "quantas caixas de iogurte mandar para a loja X amanhã", a acurácia que importa é por produto, por loja, por dia. Uma média mensal da rede esconde exatamente o erro que gera a ruptura. Defina também o mínimo aceitável: a partir de que erro a recomendação deixa de ser útil para quem decide?

4 · BLOCO E Chegar a tempo e ser usada

Uma previsão excelente que chega depois do pedido fechado vale zero. Davenport e Ronanki (2018) analisaram 152 projetos de IA e ouviram 250 executivos. O obstáculo mais citado foi a **integração com processos e sistemas existentes (47%)**, à frente de custo (40%) e de gestores que não entendem a tecnologia (37%).
`percepção de executivos`

Integração não é só técnica. É saber **em que momento** a recomendação aparece, **em que tela**, para **quem**, e **o que essa pessoa pode fazer com ela**. Por isso a condição 2 do ELO pergunta pela integração ao fluxo de trabalho, e a condição 3 pela tradução em ação.

Adoção custa dinheiro, e precisa estar no orçamento

Fountaine, McCarthy e Saleh (2019), da McKinsey, relatam que quase **90% das empresas que conseguiram escalar a IA gastaram mais da metade do orçamento de analytics em adoção**: treinamento, redesenho de processo, gestão da mudança. Entre as demais, só 23% fizeram isso. A regra que propõem: gastar com adoção pelo menos o mesmo que com tecnologia. `levantamento de consultoria`

> PERGUNTAS DO BLOCO E
> 1. **A recomendação chega antes da decisão?** Desenhe a linha do tempo: dado disponível → modelo roda → recomendação aparece → decisão é tomada.
> 2. **Como o uso fica registrado?** O sistema grava se a recomendação foi *aberta*, *aceita*, *ajustada* ou *ignorada*? Sem esse registro, ninguém saberá se a solução foi usada.
> 3. **O ajuste humano é registrado?** Quem mudou, quanto mudou, em que direção e por quê.
> 4. **Quem é dono da ação, e tem recurso para agir?** Um alerta de manutenção sem técnico disponível, ou uma sugestão de compra sem orçamento, não vira resultado.

5 · BLOCO E O ajuste humano

Na maior parte das operações, a IA recomenda e uma pessoa decide. Esse filtro humano pode melhorar ou piorar o resultado. Três estudos revisados por pares ajudam a entender como.

Ajustes pequenos e otimistas costumam piorar

Fildes, Goodwin, Lawrence e Nikolopoulos (2009) analisaram **mais de 60.000 previsões** em quatro empresas de supply chain. Os planejadores ajustavam as previsões do sistema. Em três das quatro empresas, os ajustes melhoraram a acurácia em média. Mas o detalhe importa: **ajustes pequenos frequentemente pioraram** a previsão, e **ajustes para cima** erraram de direção com mais frequência. Os autores sugerem viés de otimismo. Ajustes grandes, feitos quando a pessoa sabe algo que o sistema não sabe (uma promoção, uma obra na rua), tenderam a ajudar mais.

As pessoas usam mais o algoritmo se puderem mexer um pouco

Dietvorst, Simmons e Massey (2018) mostraram, em experimentos com tarefas de previsão, que as pessoas abandonam algoritmos depois de vê-los errar, mesmo quando o algoritmo é melhor que elas. Mas foram

> "muito mais propensas a usar o algoritmo imperfeito quando podiam modificar suas previsões."
>
> `Dietvorst et al., 2018 (tradução livre)`

E o desempenho final foi melhor. Curiosamente, o tamanho permitido do ajuste quase não importou: as pessoas querem *algum* controle, não controle total.

A confiança cai rápido depois de um erro visível

Glikson e Woolley (2020) revisaram duas décadas de pesquisa sobre confiança em IA. Para a IA "embutida" em sistemas, como um planejador de demanda dentro do ERP, a confiança **começa alta, cai de forma abrupta depois de erros e se recupera devagar**. Na prática: uma ruptura visível, causada pela recomendação, pode derrubar o uso por meses.

Implicação para o Canvas. Desenhe o ajuste humano de propósito. Permita um ajuste limitado, peça uma justificativa curta para ajustes grandes e registre tudo. Assim, depois de alguns meses, dá para saber se a combinação "sistema + pessoa" está ganhando do sistema sozinho, ou da pessoa sozinha.

6 · BLOCO F Medir com uma comparação

O degrau 4 da escada exige duas coisas: um **indicador com linha de base** (como estava antes) e um **grupo de comparação no mesmo período** (quem não usou a solução). Sem o grupo de comparação, qualquer mudança de mercado, de estação ou de preço se confunde com o efeito da IA.

Onde há comparação, os ganhos são modestos

O caso Zara é um exemplo raro de resultado medido com comparação. A empresa passou a decidir as remessas de seus centros de distribuição para cerca de 1.500 lojas com um modelo matemático de otimização alimentado por previsão de demanda. O efeito foi avaliado num experimento de campo controlado: **aumento estimado de 3% a 4% nas vendas** (Caro, Gallien et al., 2010). `independente · finalista de prêmio com júri` Os autores também relatam dificuldades técnicas e humanas significativas na implantação.

O padrão se repete na pesquisa que sustenta este seminário: onde há júri ou experimento, os ganhos ficam na faixa de **1% a 4%**. As cifras grandes e redondas ("40% mais acurado", "acurácia 15 vezes maior") costumam ser `auto-reportadas` e sem comparação.

EXEMPLO DE COMPARAÇÃO FRACA · WALMART E NEGOCIAÇÃO AUTOMATIZADA

Num piloto de três meses no Walmart Canadá, um robô de negociação fechou acordo com **64% dos fornecedores, contra uma meta de 20%**, com economia média de 1,5%. `auto-reportado · coautoria da empresa` O comparador foi uma **meta**, não um grupo de fornecedores negociados por humanos no mesmo período. E a alternativa real era não negociar esses contratos pequenos. O ganho mais defensável é de *cobertura*, não de habilidade de negociação.

Percepção não é medição

O exemplo mais forte vem de fora de operações. Num experimento da METR (2025), com sorteio de tarefas, 16 desenvolvedores experientes resolveram 246 tarefas reais com e sem IA. Com IA, **levaram 19% mais tempo**. Antes, previam ganhar 24%. Depois, **ainda acreditavam ter sido 20% mais rápidos**. `pré-registrado · não revisado por pares`

Na mesma linha, Humlum e Vestergaard (2025) cruzaram respostas de cerca de 25.000 trabalhadores dinamarqueses com registros administrativos. A economia de tempo declarada foi de 2,8% das horas. O efeito medido em salários e horas trabalhadas foi próximo de zero.

> PERGUNTAS DO BLOCO F
>
> 1. **Qual indicador e qual linha de base?** Ex.: taxa de ruptura por loja nas últimas 12 semanas, antes da solução.
> 2. **Qual grupo de comparação, no mesmo período?** Ex.: metade das lojas com o sistema e metade sem, sorteadas; ou um grupo de categorias de produto que fica de fora por três meses.
> 3. **Quem paga pelo ganho?** (próxima seção)

7 · BLOCO F Quem paga pelo ganho

Um ganho no indicador ainda não é valor líquido. Duas perguntas ajudam a chegar lá.

O ganho foi criado ou só mudou de lugar? Um modelo que prioriza os clientes ou produtos mais valiosos pode melhorar o serviço deles à custa dos demais. O indicador do piloto sobe, e a perda aparece em outro lugar. A pesquisa não encontrou estudos em operações que quantifiquem esse efeito. Trate como hipótese a verificar, não como fato. Mas inclua na medição: olhe também quem *não* recebeu a prioridade.

Quanto custa manter funcionando? Engenheiros do Google descreveram a "dívida técnica escondida" dos sistemas de aprendizado de máquina (Sculley et al., 2015). Construir e implantar é relativamente rápido e barato.

> "...mas mantê-los ao longo do tempo é difícil e caro." `Sculley et al., 2015 (tradução livre)`

Num sistema maduro, o código que "aprende" pode ser no máximo 5% do total; o resto é integração, dados e monitoramento. E o mundo muda: na pandemia, uma métrica interna de acurácia da Instacart caiu de 93% para 61%, porque os dados de treino não refletiam a nova realidade. Retreinar, monitorar e corrigir são custos recorrentes. Culot et al. (2024) também notam que o custo de manutenção cresce com a complexidade da solução.

Conta mínima para o Canvas: ganho medido (com comparação) − custo da tecnologia − custo de adoção (treino, redesenho, gestão da mudança) − custo recorrente de manutenção e monitoramento − ganho que apenas mudou de lugar = **valor líquido**.

8 · CHECKLIST Para levar à Sessão 2

Traga o Canvas da Sessão 1. Com o grupo, rascunhe as respostas abaixo antes da aula. Onde faltar informação, escreva "não sei": é uma resposta válida e útil. O coach de IA pode oferecer dados hipotéticos, sempre sinalizados como didáticos.

D · EVIDÊNCIA

- [ ] Que prova existe de que soluções parecidas funcionam? Em que degrau da escada ela está (1, 2, 3 ou 4)?
- [ ] Quem mediu? Quem mediu vende a solução ou tem interesse no resultado?
- [ ] **D2** Quão boa a solução precisa ser, medida no nível de detalhe da decisão (uma decisão, não um dado)? Qual o mínimo aceitável?

E · IMPLANTAÇÃO · CONDIÇÕES 2 E 3 DO ELO

- ☐ A recomendação chega antes da decisão? Em que momento, em que tela, para quem?
- ☐ Como o uso é registrado: aberta, aceita, ajustada, ignorada?
- ☐ O ajuste humano é registrado (quem, quanto, em que direção, por quê)?
- ☐ Quem é dono da ação? Há recursos (pessoas, orçamento, capacidade) para agir?

F · RESULTADO E VALOR · CONDIÇÕES 4 E 5 DO ELO

- ☐ Qual indicador operacional e qual linha de base?
- ☐ Qual grupo de comparação, no mesmo período?
- ☐ Quem paga pelo ganho? O ganho foi criado ou mudou de lugar? Quais os custos de adoção e manutenção?

G · ELO ANTES DA ADOÇÃO

As seis condições do ELO (Lima & Araujo, COPPEAD/UFRJ, pesquisa em andamento). Marque uma coluna por linha.

CONDIÇÃO	SIM	EM PARTE	NÃO	NÃO SEI
0 · Base de evidência: há prova, em degrau alto, de que soluções assim funcionam?	☐	☐	☐	☐
1 · Capacidade técnica em operação: funciona com os nossos dados, no nosso nível de detalhe, ao longo do tempo?	☐	☐	☐	☐
2 · Integração ao fluxo de trabalho: chega a tempo, no lugar certo, e o uso é registrado?	☐	☐	☐	☐
3 · Tradução em ação: alguém dono da ação decide e age, com recursos?	☐	☐	☐	☐
4 · Resultado organizacional: o indicador muda, contra um grupo de comparação?	☐	☐	☐	☐
5 · Valor líquido: o ganho supera os custos e não apenas mudou de lugar?	☐	☐	☐	☐

Onde a corrente deve quebrar primeiro? Escolha uma condição e explique em uma frase. É essa a hipótese que o grupo vai testar na Sessão 3.

9 Referências

Caro, F., Gallien, J., et al. (2010). Zara uses operations research to reengineer its global distribution process. *Interfaces*, 40(1), 71–84. econpapers.repec.org/RePEc:inm:orinte:v:40:y:2010:i:1:p:71-84

Culot, G., Podrecca, M., & Nassimbeni, G. (2024). Artificial intelligence in supply chain management: A systematic literature review of empirical studies and research directions. *Computers in Industry*, 162, 104132. aisberg.unibg.it/bitstream/10446/276769

Davenport, T. H., & Ronanki, R. (2018). Artificial intelligence for the real world. *Harvard Business Review*. deloitte.com · us-deloitte-analytics-hbr-ai-for-the-real-world.pdf

Dietvorst, B. J., Simmons, J. P., & Massey, C. (2018). [Aversão a algoritmos e modificação de previsões]. *Management Science*, 64(3), 1155–1170. ideas.repec.org/a/inm/ormnsc/v64y2018i3p1155-1170.html

Fildes, R., Goodwin, P., Lawrence, M., & Nikolopoulos, K. (2009). Effective forecasting and judgmental adjustments: An empirical evaluation and strategies for improvement in supply-chain planning. *International Journal of Forecasting*, 25(1), 3–23. econpapers.repec.org/RePEc:eee:intfor:v:25:y:2009:i:1:p:3-23

Fountaine, T., McCarthy, B., & Saleh, T. (2019). Building the AI-powered organization. *Harvard Business Review*, jul.–ago. 2019 (R1904C). R1904C-PDF-ENG_FINAL.PDF

Glikson, E., & Woolley, A. W. (2020). Human trust in artificial intelligence: Review of empirical research. *Academy of Management Annals*, 14(2), 627–660. doi.org/10.5465/annals.2018.0057

Humlum, A., & Vestergaard, E. (2025). *Large language models, small labor market effects* (BFI Working Paper 2025-56). University of Chicago. bfi.uchicago.edu · BFI_WP_2025-56-3.pdf

Lima, T. F., & Araujo, C. A. S. (em andamento). *ELO: Evidência, Lógica organizacional e Operação*. Pesquisa de pós-doutorado, COPPEAD/UFRJ.

Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2022). M5 accuracy competition: Results, findings, and conclusions. *International Journal of Forecasting*, 38(4). pré-print · M5_accuracy_competition.pdf · editorial do número especial: pmc.ncbi.nlm.nih.gov/articles/PMC9232271

METR (2025). Estudo controlado sobre o efeito de ferramentas de IA na produtividade de desenvolvedores experientes (pré-registrado, não revisado por pares). Resumo em DX: getdx.com/blog/metr-study-on-how-ai-affects-developer-productivity

Sculley, D., Holt, G., Golovin, D., Davydov, E., Phillips, T., Ebner, D., Chaudhary, V., Young, M., Crespo, J.-F., & Dennison, D. (2015). Hidden technical debt in machine learning systems. *NeurIPS 2015*. proceedings.neurips.cc · 86df7dcf…-Paper.pdf

Instacart (queda de acurácia na pandemia): Fortune, 9 jun. 2020. fortune.com/2020/06/09/instacart-coronavirus-artificial-intelligence

Walmart e negociação automatizada (números auto-reportados): ProcureCon. procureconsupplychain.wbresearch.com · walmart-ai-chatbot-automate-supplier-negotiations