LEITURA PRÉVIA · SESSÃO 3 · IA APLICADA A OPERAÇÕES, PROCESSOS E SUPPLY CHAIN

Seis meses depois: auditar uma solução de IA com o ELO

Como ler um relatório de operação que parece bom, achar o ponto em que a cadeia rompe e escrever um parecer que alguém possa executar.

COPPEAD/UFRJ · Ênfase em IA | Prof. Dr. Thiago Lima | Leitura: ~30 min

1 Um painel que parece bom

Imagine que o grupo de vocês implantou a solução desenhada nas Sessões 1 e 2. Seis meses se passaram. A diretoria recebe o painel abaixo.

PAINEL EXECUTIVO · REPOSIÇÃO COM IA · REDE ATLÂNTICA (22 LOJAS) · 6 MESES
FICTÍCIO · DIDÁTICO

ACERTO DA PREVISÃO **91%** meta 85% ✓	COMPRADORES QUE ACESSAM **94%** adoção alta ✓	SUGESTÕES GERADAS **412 mil** sem falhas de sistema ✓
RUPTURA NAS LOJAS **−18%** de 5,1% para 4,2% ✓	COMPRADORES SATISFEITOS **87%** "trabalho mais rápido" ✓	CUSTO DO PROJETO **R$ 1,46 mi** 97% do orçado ✓

Referência do fornecedor: "93% de acerto em clientes do setor". Empresa, números e falas são fictícios, criados para esta leitura.

Seis indicadores verdes. A tentação é aprovar a expansão. Esta leitura prepara vocês para fazer o contrário: **não acreditar nem desacreditar**, e sim perguntar, número por número, o que cada um prova.

Na Sessão 3, o coach de IA vai gerar um relatório fictício de seis meses da solução do grupo de vocês. Ele vai esconder de uma a três falhas. Vocês vão auditar condição por condição, citando números, escrever um parecer e apresentá-lo à turma. Voltaremos a este painel na seção 4.

2 A cadeia ELO

O **ELO** (Evidência · Lógica organizacional · Operação) é um framework de Lima & Araujo, do COPPEAD/UFRJ, em pesquisa em andamento. Ele foi derivado de uma revisão de implantações de IA em hospitais. Aqui ele é usado como **estrutura de raciocínio**, não como resultado validado.

A ideia central: entre uma ferramenta que funciona e um resultado medido na organização existem seis condições. Cada uma é **necessária**. Nenhuma é **suficiente**.

0	1	2 · organização	3 · organização	4	5
Base de evidências Há prova de que isso funciona em operação real?	Capacidade em operação Acerta nos nossos dados, no nível da decisão?	Integração ao fluxo Chega a quem decide, na hora, e é usada?	Tradução em ação Alguém age, com recursos para isso?	Resultado organizacional O indicador muda, medido com comparação?	Valor líquido O ganho compensa o custo? Quem paga?

Caixas com borda grossa: capacidades da organização, não da ferramenta.

Três regras de leitura:

- **As condições 2 e 3 são da empresa, não do software.** Nenhum fornecedor entrega pronto o hábito de usar a recomendação, a alçada para agir ou a equipe para executar.
- **A ruptura é o primeiro "Não".** Vocês marcam cada condição como Sim, Em parte, Não ou Não medido. Uma condição posterior não compensa uma anterior: se ninguém age (3), o resultado (4) não pode vir da solução.
- **Não há nota.** Uma média de 4 em 6 esconde justamente onde a cadeia para. O ELO aponta um lugar, não um número.

"Não medido" não é "Sim". Se o relatório não traz o dado, registrem isso. No parecer, a cadeia não pode ser dada como íntegra naquele ponto.

3 Como cada condição aparece nos dados

Para cada condição: o que procurar no relatório e um padrão real, documentado, em que ela falhou.

0 · Base de evidências — validação do fornecedor não é validação externa

Procurem: quem mediu o desempenho prometido, em que dados, e se essa pessoa vende a solução.

Há uma escada de evidência com quatro degraus: (1) número do modelo; (2) benefício esperado, de simulação ou proposta comercial; (3) percepção de usuários; (4) resultado medido com comparação. A revisão de Culot, Podrecca & Nassimbeni (2024), com 123 estudos com dados reais, concluiu que os benefícios relatados são, na maior parte, expectativas ou percepções.

PADRÃO REAL · EPIC SEPSIS MODEL

Modelo de alerta de sepse usado por cerca de 170 clientes da Epic. Uma validação externa na Universidade de Michigan, com 38.455 internações, encontrou uma AUC de 0,63, contra 0,76 a 0,83 informados (Wong et al., *JAMA Internal Medicine*, 2021). A AUC é uma nota de 0,5 (igual a sortear) a 1,0 (separa perfeitamente quem tem e quem não tem a doença). O modelo deixou de detectar 67% dos casos de sepse e alertou 18% de todos os pacientes. A Epic contestou o limite de alerta usado no estudo.

1 · Capacidade em operação — o total e o detalhe; o mundo muda

Procurem: o erro medido no mesmo nível da decisão (item, loja, semana), por segmento, e mês a mês.

Um modelo pode acertar bem o total e errar muito onde a decisão acontece. E pode acertar por meses e cair depois de um evento: novo canal, troca de fornecedor, campanha. Isso se chama **mudança nos dados** (em inglês, *data drift*): o mundo deixa de se parecer com o histórico em que o modelo aprendeu.

PADRÃO REAL · COMPETIÇÃO M5
Com 42.840 séries de vendas da Walmart, o vencedor foi 22,4% melhor que o melhor método estatístico simples. No nível produto-loja, onde a reposição acontece, o ganho foi de ~3%. Só 7,5% das equipes bateram o método simples (Makridakis et al., 2022).

PADRÃO REAL · INSTACART, MARÇO DE 2020
O acerto do modelo de disponibilidade de itens caiu de 93% para 61% a partir de meados de março. Os dados de treino não refletiam a nova realidade da pandemia. Com treino em até dez dias de dados e cálculo de hora em hora, voltou a ~85% (Fortune, 2020). `métrica não definida na fonte`

2 · Integração ao fluxo — acessar não é usar; chegar tarde é não chegar

Procurem: recomendações geradas, abertas, aceitas como vieram, ajustadas e ignoradas, mês a mês; o horário em que a recomendação chega e o horário em que a decisão fecha.

Login não é uso. Uso concentrado em poucas pessoas é adoção frágil. E uma sugestão que chega às 10h para um pedido que fecha às 9h vale zero, por melhor que seja. O tempo é parte da integração.

PADRÃO REAL · INTEGRAÇÃO E ADOÇÃO
Em 152 projetos, integrar a IA a processos e sistemas existentes foi o obstáculo nº 1, citado por 47% (Davenport & Ronanki, 2018). No ORION, roteirizador da UPS, as primeiras rotas não funcionaram no campo; a empresa teve de fazer o algoritmo "pensar mais como um motorista" (INFORMS, 2016). Quase 90% das empresas que escalaram IA gastaram mais da metade do orçamento em adoção, contra 23% das demais (Fountaine et al., 2019).

3 · Tradução em ação — o ajuste humano e os recursos para agir

Procurem: quantas recomendações foram ajustadas, em que direção, e o resultado das ajustadas contra as não ajustadas; casos certos que ficaram sem ação, e por quê.

O resultado medido é sempre **modelo + ajuste humano + execução**. Se o ajuste não fica registrado, ninguém sabe qual dos três produziu o número. E uma recomendação certa sem gente, alçada ou capacidade para executá-la não vira resultado.

PADRÃO REAL · AJUSTES DE PREVISÃO
Em mais de 60.000 previsões de quatro empresas de supply chain, ajustes pequenos frequentemente pioraram o acerto. Ajustes para cima foram bem menos propensos a melhorar: viés de otimismo (Fildes et al., 2009). As pessoas usam mais o algoritmo quando podem ajustá-lo um pouco (Dietvorst et al., 2018).

PADRÃO REAL · O MODELO DE PRECIFICAÇÃO DO ZILLOW OFFERS
No 3º trimestre de 2021, a Zillow comprou 9.680 casas e vendeu 3.032. A receita ficou em US$ 1,19 bi, abaixo da faixa de US$ 1,4 a 1,5 bi, por "renovation and resale capacity constraints" (Zillow, 2021). Em outubro, pausou novas compras por falta de capacidade de reforma. Em novembro, encerrou a operação.

4 · Resultado organizacional — comparado a quê?

Procurem: a linha de base de 12 meses (para ver a sazonalidade), um grupo que ficou sem a solução no mesmo período, e a diferença entre percepção e registro.

"Antes e depois" mistura o efeito da solução com sazonalidade, mix e choques externos. A comparação forte é com uma parte da operação que seguiu sem a solução no mesmo período. Pesquisa de satisfação mede crença, não resultado.

PADRÃO REAL · PERCEPÇÃO × REGISTRO (METR, 2025)
Em um experimento com 16 desenvolvedores experientes e 246 tarefas reais, quem usou IA levou 19% mais tempo. Antes, esperavam ganhar 24%. Depois, ainda achavam ter ficado 20% mais rápidos. São quase 40 pontos entre o que sentiram e o que foi medido. `pré-registrado, não revisado por pares`

5 · Valor líquido — quem paga e o custo que não aparece

Procurem: custo total do período (não só do projeto); horas de revisão, correção de cadastro e retreino; indicadores de áreas vizinhas.

O ganho pode estar só deslocado: o foco melhora e outra área piora. E o custo de manter costuma ser maior que o de construir.

PADRÃO REAL · MANUTENÇÃO ESCONDIDA (SCULLEY ET AL., 2015)
Engenheiros do Google descreveram sistemas de aprendizado de máquina como "relativamente rápidos e baratos de construir", mas "difíceis e caros de manter". Num sistema maduro, o modelo pode ser no máximo 5% do código. O resto é a "cola" que o liga a dados e sistemas, e essa dívida cresce em silêncio.

4 Ler um relatório como auditor

Cinco perguntas, nesta ordem, para cada número que parecer bom:

AS CINCO PERGUNTAS DO AUDITOR

1. **Que número sustenta isto?** Não a frase do relatório: o número, a seção e a coluna.
2. **Comparado a quê?** Meta, ano anterior, unidades sem a solução? A meta não é um grupo de comparação.
3. **Em que nível de detalhe?** O mesmo nível da decisão, ou um total que esconde o detalhe?
4. **Quem ajustou?** O número é do modelo, do humano que mudou a sugestão, ou da execução?
5. **Quem pagou?** Que custo, área ou cliente ficou fora da conta?

Agora, o painel da seção 1, aberto com as cinco perguntas:

O PAINEL REVISITADO · O QUE APARECEU AO ABRIR CADA NÚMERO FICTÍCIO · DIDÁTICO

INDICADOR	PERGUNTA	O QUE O RELATÓRIO MOSTRAVA	COND.
91% de acerto	Nível?	Medido no total mensal da rede. Por item-loja-semana, nível da decisão: 64%. Itens de baixo giro: 52%.	**1 · Não**
94% acessam	Número?	Só 46% das sugestões foram aceitas como vieram. Em 6 lojas, a sugestão chega às 10h de segunda; o pedido fecha às 9h.	**2 · Em parte**
412 mil sugestões	Quem ajustou?	38% foram ajustadas, 81% delas para cima. Ruptura igual à das não ajustadas, com 11% mais estoque.	**3 · Em parte**
Ruptura −18%	Comparado a quê?	Ao semestre anterior, que teve greve de transportadores. As 4 lojas sem a solução caíram 15% no mesmo período.	**4 · Em parte**
87% satisfeitos	Número?	23 de 40 compradores responderam. O registro mostra 15 minutos a mais por semana em cada pedido.	**4 · percepção**
R$ 1,46 mi	Quem pagou?	Só o projeto. Ficaram fora 2 analistas corrigindo cadastro em tempo integral e um retreino emergencial em abril.	**5 · Não medido**

Repare: a condição 0 também merece olhar. Os 93% do fornecedor vêm de outros clientes, sem comparação. É degrau 1 da escada, não degrau 4.

A primeira pergunta também vale para casos reais. No 3º trimestre de 2021, a métrica de retorno por casa que a Zillow divulgava seguiu positiva (+2,37%), porque excluía a baixa contábil do estoque. No mesmo trimestre, o lucro bruto contábil foi de −US$ 80.771 por casa vendida (Zillow, 2021). Os dois números são verdadeiros. Só um deles sustenta uma decisão.

5 As quatro dívidas e como ordená-las

Dívida é algo que ficou para depois e cobra juros. O parecer pede que vocês nomeiem a **dívida principal** por trás da ruptura.

DÍVIDA	O QUE É	SINAIS NO RELATÓRIO
Técnica	Modelo, dados e manutenção (Sculley et al., 2015).	Erro alto no detalhe; queda depois de um evento; retreino ou correção de dados não previstos.
Filosófica	Premissas não escritas sobre **para que** a solução serve, **o que conta como prova** e **o que ela enxerga**. Termo de Lima (2026), inspirado nos pilares de Schrage & Kiron (2025).	A solução acerta a meta errada; o conflito custo × serviço foi decidido por omissão; o acerto foi definido num nível que não é o da decisão.
De adoção	O trabalho não mudou para receber a recomendação.	Uso baixo ou concentrado; sugestão fora do horário; ajuste sem registro.
De capacidade	A organização não consegue agir ou supervisionar.	Casos certos sem ação; falta de gente, alçada ou capacidade física; ninguém com competência para questionar o modelo.

Como escolher a principal, quando há mais de uma:

- **Qual explica o primeiro "Não"?** A dívida principal é a da ruptura, não a maior em valor.
- **Pagá-la destrava as condições seguintes?** Corrigir o horário da sugestão (2) pode mudar o uso (2), os ajustes (3) e o resultado (4).
- **Tem dono que possa agir em semanas?** Uma dívida sem dono não é dívida; é risco aceito sem saber.

As demais dívidas entram no parecer como lista, não como causa.

6 Quem responde por isso

A regulação está chegando à mesma pergunta do ELO: quem decide e quem responde. Na Europa, o AI Act (Regulamento UE 2024/1689) dá deveres a quem **usa** um sistema de IA de alto risco, não só a quem o vende. O Art. 26 pede, entre outros pontos:

ART. 26 DO AI ACT	CONDIÇÃO
Supervisão humana por pessoas com competência, formação e autoridade (§2)	**2 · 3**
Dados de entrada relevantes e suficientemente representativos (§4)	**1**
Registros (logs) guardados por pelo menos seis meses (§6)	**2 · 4**

Informar trabalhadores e seus representantes antes do uso no local de trabalho (§7)	**2**

Prazos. Os deveres para os usos de alto risco do Anexo III valeriam em 02/08/2026. O acordo político do *Digital Omnibus*, de 06/05/2026, adiou-os para 02/12/2027. `publicação no Jornal Oficial a confirmar`

Brasil. O PL 2338/2023 foi aprovado pelo Senado em 10/12/2024. Em novembro de 2026, segue na Câmara, aguardando o parecer do relator na Comissão Especial.

Confiram no texto oficial se o uso de vocês está no Anexo III. A lista não foi verificada nesta pesquisa.

O ponto para o parecer: a competência para supervisionar o modelo não se terceiriza ao fornecedor. A lei transforma as condições 2 e 3 em obrigação.

7 O parecer e a apresentação

ESTRUTURA DO PARECER · MEIA PÁGINA

1. Primeira condição com "Não" — e o número que a sustenta.

2. Previsto × ocorrido — onde vocês previram a ruptura na Sessão 2, onde ela aconteceu.

3. Dívida principal — técnica, filosófica, de adoção ou de capacidade, em uma frase.

4. Decisão — prosseguir · prosseguir sob condições nomeadas · pausar · não prosseguir.

5. Primeiro passo — o quê, quem (cargo) e até quando.

Condição nomeada é mensurável, tem dono e tem data. "Melhorar a adoção" não é condição. "Aceitação sem ajuste acima de 60% em 90 dias, medida pelo gerente de planejamento" é.

Pausar é parar o uso nas decisões e manter o registro e o aprendizado, com critério para voltar. **Não prosseguir** é encerrar e dizer o que se aprendeu.

Lembrem: o relatório é fictício. O parecer julga o **raciocínio** do grupo, não a solução.

EXEMPLO DE PARECER · REDE ATLÂNTICA `FICTÍCIO · DIDÁTICO`

Ruptura na condição 1. O acerto de 91% é do total mensal; no nível da decisão (item-loja-semana) é 64%. **Previsto × ocorrido:** previámos ruptura na condição 2; ela veio antes, e 2 e 3 estão "em parte". **Dívida principal: filosófica** — definimos "acerto" num nível que não é o da decisão, e ninguém revisou essa premissa. **Decisão: prosseguir sob condições** — acerto por item-loja-semana medido mensalmente, sugestão disponível até sexta às 18h, todo ajuste registrado. **Primeiro passo:** o gerente de planejamento refaz o painel no nível da decisão em 30 dias.

Roteiro da apresentação

0:00–0:30	A solução em uma frase: que decisão apoia, para quem.
0:30–1:30	Onde previram a ruptura e onde ela ocorreu, com **um** número.
1:30–2:30	A dívida principal e por que ela, e não as outras.
2:30–3:30	A decisão e as condições nomeadas.
3:30–4:00	O primeiro passo: o quê, quem, até quando.

Um slide basta. Se precisarem de mais de um número por condição, o parecer ainda não escolheu.

Para levar à Sessão 3

- [ ] O resumo das Sessões 1 e 2, completo, para colar no coach (canvas, ELO antes da adoção, dados didáticos, decisões em aberto).
- [ ] A condição em que vocês previram a ruptura na Sessão 2 — por escrito, antes de ver o relatório.
- [ ] As cinco perguntas do auditor, à mão.
- [ ] Uma pessoa do grupo responsável por anotar, para cada condição, a marcação e o número que a sustenta.
- [ ] Um modelo de parecer em branco com os cinco campos da seção 7.
- [ ] A regra: "Não medido" não é "Sim"; não há nota; a ruptura é o primeiro "Não".

REF. Referências

Culot, G., Podrecca, M., & Nassimbeni, G. (2024). *Computers in Industry*, 162, 104132. aisberg.unibg.it/bitstream/10446/276769

Davenport, T. H., & Ronanki, R. (2018). Artificial intelligence for the real world. *Harvard Business Review*. deloitte.com/…/us-deloitte-analytics-hbr-ai-for-the-real-world.pdf

Dietvorst, B. J., Simmons, J. P., & Massey, C. (2018). *Management Science*, 64(3), 1155–1170. ideas.repec.org/a/inm/ormnsc/v64y2018i3p1155-1170.html

Fildes, R., Goodwin, P., Lawrence, M., & Nikolopoulos, K. (2009). *International Journal of Forecasting*, 25(1), 3–23. econpapers.repec.org/RePEc:eee:intfor:v:25:y:2009:i:1:p:3-23

Fortune (09/06/2020). Reportagem sobre o modelo de disponibilidade da Instacart na pandemia. Fonte primária da empresa não localizada. fortune.com/2020/06/09/instacart-coronavirus-artificial-intelligence

Fountaine, T., McCarthy, B., & Saleh, T. (2019). *Harvard Business Review*. investkl.gov.my/…/R1904C-PDF-ENG_FINAL.PDF

Gibson Dunn (27/05/2026). EU AI Act omnibus agreement: postponed high-risk deadlines. gibsondunn.com/eu-ai-act-omnibus-agreement-postponed-high-risk-deadlines-and-other-key-changes

Habib, A. R., Lin, A. L., & Grant, R. W. (2021). Editorial sobre Wong et al. *JAMA Internal Medicine*, 181(8), 1040–1041. Dados de Wong et al. (2021) conforme o editorial e a cobertura; artigo original não consultado. jamanetwork.com/journals/jamainternalmedicine/fullarticle/2781313 · Resposta da Epic: fiercehealthcare.com/tech/epic-s-widely-used-sepsis-prediction-model…

INFORMS (2016). ORION, *OR/MS Today*. pubsonline.informs.org/do/10.1287/orms.2016.03.10/full

Lima, T. F. (2026). *Excelência Operacional* (conceito de dívida filosófica).

Lima, T. F., & Araujo, C. A. S. ELO: Evidência · Lógica organizacional · Operação. COPPEAD/UFRJ, pesquisa em andamento. Protótipo: tflsixsigma-png.github.io/IA-Gestao-Hospitalar-Prof-Thiago-Lima/elo

Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2022). M5 accuracy competition. *International Journal of Forecasting*, 38(4). Pré-print: statmodeling.stat.columbia.edu/…/M5_accuracy_competition.pdf

METR (2025). Experimento controlado com desenvolvedores; pré-registrado, não revisado por pares. Resumo: getdx.com/blog/metr-study-on-how-ai-affects-developer-productivity

PL 2338/2023. Ficha no Congresso Nacional: congressonacional.leg.br/…/materia/157233 · Tramitação na Câmara (monitor secundário; ficha oficial da Câmara não acessada): monitor.lcfconsulting.com.br/proposicoes/pl-2338-2023 · casrai.org/guides/brazil-ai-bill-pl-2338-status

Regulamento (UE) 2024/1689 (AI Act), Art. 26. springlex.eu/en/packages/ai-act/ai-act-regulation/article-26

Schrage, M., & Kiron, D. (2025). Philosophy eats AI. *MIT Sloan Management Review*. sloanreview.mit.edu/article/philosophy-eats-ai

Sculley, D., et al. (2015). Hidden technical debt in machine learning systems. *NeurIPS*. proceedings.neurips.cc/paper/2015/file/86df7dcfd896fcaf2674f757a2463eba-Paper.pdf

Zillow Group (02/11/2021). Carta aos acionistas, release e tabelas do 3T21 (SEC, 8-K). sec.gov/…/000161764021000085/exhibit993.htm · q32021991.htm · q32021992.htm · Pausa de out/2021 (imprensa): inman.com/2021/10/18/zillow-hits-brakes-on-buying-new-homes…